

Lineáris függvényillesztés

2019. február 11.

Elméleti modell

Az elméleti modell bizonyos x_i *változók* és a *paraméterek* függvényében *becslést ad* a mérhető fizikai mennyiségek értékeire.

A modell sokféle lehet:

- ▶ tisztán matematikai: függvényillesztés
ilyenkor az x_i értékeket adottak, és az a paramétereket kell variálni úgy, hogy a modell által adott $y(x_i|a)$ becslések jól illeszkedjenek az y_i mért értékekre.

$$y(x_i|a) = f(x_i, a)$$

- ▶ szimulációs: numerikus algoritmus, stb. (ld. később)

Kérdések:

- ▶ mennyire jó egy modell?
- ▶ a mérések alapján melyik a legjobb modell?
- ▶ hogyan találjuk meg a legjobb modellt?

Melyik a legjobban illeszkedő modell?

Ha a modell szerint a mérési eredmények egymástól *függetlenek*, és kizárólag az x_i értékektől és az ismeretlen θ paraméterektől függenek, akkor használhatjuk a *legnagyobb valószínűség*¹ módszerét.

A mért y_i értékek sosem pontosak. Konkrét mérés esetében egy adott mért érték mindig csak valamilyen $P(y_i)$ valószínűséggel fordul elő.

- ▶ a hibáról magáról is felteszünk valamit, ez is a modell része
- ▶ a $P(y_i)$ valószínűség eloszlása megismételt mérésekkel elvileg megbecsülhető
- ▶ standard hiba esetében ez normális eloszlás a mérési hibának megfelelő σ szórással

¹angolul: maximum likelihood

A *likelihood*-függvény

Kérdés: Mi annak a valószínűsége, hogy a modell egy adott a paraméterezése mellett a méréssorozat pont a mért y_i értékeket adja?

Legyen $p(y_i|x_i, a)$ annak a valószínűségnek az eloszlása, hogy egy konkrét paraméterezés esetén az i . mérés éppen y_i értéket ad.

Ha a méréssorozat N független mérés egymásutánjából áll össze, akkor a méréssorozat megvalósulásának teljes valószínűségi eloszlása adott a paraméterek esetén:

$$L(a) = \prod_i^N p(y_i|x_i, a)$$

Ez az ún. *likelihood-függvény*, aminek a maximumát keressük az a paraméterek variálása mellett.

A likelihood-függvény normális eloszlású hiba esetén

Tegyük fel, hogy $p(y_i|x_i, a)$ a Gauss-eloszlás, azaz a mért érték normális eloszlású a modell által becsült érték körül σ_i szórással:

$$p(y_i|x_i, a) = \frac{1}{\sigma_i\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{y_i - y(x_i|a)}{\sigma_i} \right)^2 \right]$$

Ezzel pedig a likelihood-függvény:

$$L(a) = \prod_i \left\{ \frac{1}{\sigma_i\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{y_i - y(x_i|a)}{\sigma_i} \right)^2 \right] \right\}$$

Keressük a likelihood-függvény maximumát, azaz:

$$\arg \max_a L(a) = ?$$

A likelihood-függvény logaritmusa

$L(a)$ kifejezésében a produktum hasáiban csak pozitív számok állnak. Vegyük az egész kifejezés logaritmusát. Mivel a logaritmus monoton, $\ln L$ maximuma ugyanott lesz, ahol L maximuma.

$$\ln L(a) = \sum_i \left[-\frac{1}{2} \left(\frac{y_i - y(x_i|a)}{\sigma_i} \right)^2 \right] + C,$$

ahol a C konstans tartalmaz minden olyan tagot, ami nem függ az a paraméterektől.

Definiáljuk a következő mennyiséget:

$$\chi^2 = \sum_i \frac{[y_i - y(x_i|a)]^2}{\sigma_i^2}$$

Ez az ún. *khi-négyzet*, amiről látszik, hogy a minimuma pontosan olyan a paramétereknél van, ahol $L(a)$ maximális.

A legkisebb négyzetek módszere

Konstans, normális eloszlású hiba esetén σ kiemelhető a χ^2 kifejezéséből, így – végső soron – a maximum likelihood módszer átmegy a *legkisebb négyzetek módszerébe*:

$$\arg \min_a \sum_i [y_i - y(x_i|a)]^2 = ?$$

A számolás során x_i -ket végig ismertnek vettük.

- ▶ Általános esetben ezeknek is lehet hibájuk.

Eddig a modellről nem tettünk fel semmit:

- ▶ lehet matematikai formula
- ▶ lehet algoritmus a bemenő paraméterekkel

A χ^2 minimalizálása

Általános esetben a χ^2 bonyolult kifejezés.

- ▶ ha ismert is zárt alakban, analitikusan nehéz kezelni
- ▶ ha a modell csak algoritmikusan adott, akkor a minimum is csak algoritmikusan kezelhető

Függvények minimumának keresésére majd nézünk módszereket.

Pár érdekes eset:

- ▶ a függvény kvadratikus
- ▶ ha a függvénynek lokális minimumai vannak
- ▶ ha nagyon sok lokális minimum van

Kvadrátikus kifejezés minimuma

Mivel ez egy négyzetes kifejezés, jó eséllyel létezik minimumhelye. Ebben a pontban az a szerinti parciális deriváltak értéke 0. A konkrét esetben

$$\arg \min_a \sum_i \frac{[y_i - y(x_i|a)]^2}{\sigma_i^2} = ?$$

a következőre vezet:

$$0 = -2 \sum_i \frac{[y_i - y(x_i|a)]}{\sigma_i^2} \frac{\partial y(x_i|\dots a_k \dots)}{\partial a_k}$$

minden k -ra, ahol k a paraméterek számaig futó index.

Kérdés persze, hogy a parciális deriváltakat mennyire könnyű kiszámolni.

Az illesztett paraméterek hibája

Eddig arról volt szó, hogy a mért értékeknek van valamilyen hibájuk.

Most: elvégeztünk egy optimalizációs eljárást, ami a mérési adatok alapján megadott bizonyos a modellparamétereket. Kérdés, hogy ezek a paraméterértékek mennyire tekinthetők pontosnak.

Két különböző dolgot vizsgálhatunk:

- ▶ *hibaterjedés:*

a mérési hibából következően mekkora az illesztett paraméterek bizonytalansága

- ▶ *konfidencia intervallumok:*

mennyire lehetünk biztosak abban, hogy a mérés alapján a „valódi” paramétereket sikerült megilleszteni?
szemléletesen: mennyire romlik el az illesztés, ha a legjobban illeszkedő paramétereket egy kicsit megvariáljuk

Illesztett paraméterek hibája

Eddig azt néztük, hogy a mérési hiba hogyan propagál az illesztett paraméterekbe, ha van egy konkrét függvényünk.

- ▶ a hibaterjedés végigszámolása bonyolult esetben nem lehetséges
- ▶ főleg, ha a modell nem analitikus
- ▶ a kovarianciákat nehéz megbecsülni

Mégis hogyan lehet jellemezni az illesztett paraméterek megbízhatóságát?

Két lehetőség adódik:

- ▶ az illesztett modellparamétereket kicsit megváltoztatva mennyire rontjuk el az illesztést
- ▶ a mérést az illesztett paraméterekkel „újraszimulálva”, majd „újraillesztve” mennyire szórnak az illesztett értékek

Az illesztés jósága: redukált χ^2

A χ^2 definíció szerint:

$$\chi^2 = \sum_i \frac{[y_i - y(x_i|a)]^2}{\sigma_i^2}$$

Ez függ a mérési pontok számától, ezért két méréssorozat illesztésének jóságát nem fogjuk tudni összehasonlítani vele.

Kérdés: miként kell normálni?

N a mérési pontok száma, és M az illesztett paraméterek száma

► definiáljuk a szabadsági fokok számát: $\nu = N - M$

Redukált χ^2

- ▶ ha az illesztett modell az a paraméterekben lineáris, akkor belátható, hogy χ^2 eloszlása a minimum körül azonos az ún. ν szabadsági fokú χ^2 eloszlással
- ▶ ez ν egymástól független normális eloszlású véletlen változó összegének eloszlása, aminek a várható értéke is ν
- ▶ normáljunk tehát a szabadsági fokok számával!

Normáljuk χ^2 -et $\nu = N - M$ -mel, a szabadsági fokok számával.
Ekkor az „egész jó” illesztés feltétele:

$$\frac{\chi^2}{\nu} \approx 1$$

Aszimptotikus hiba

Egyszerű módszer a paraméterek bizonytalanságának becslésére, ha a modell analitikus alakja ismert.

Tekintsük χ^2 viselkedését a minimum körül:

- ▶ $\chi^2(\mathbf{a})$ az \mathbf{a}_0 minimum körül Taylor-sorba fejthető


$$\chi^2(\mathbf{a}) = \chi_0^2 + \left. \frac{\partial \chi^2}{\partial a_k} \right|_{\mathbf{a}_0} (\mathbf{a} - \mathbf{a}_0) + (\mathbf{a} - \mathbf{a}_0)^T \left. \frac{\partial^2 \chi^2}{\partial a_k \partial a_l} \right|_{\mathbf{a}_0} (\mathbf{a} - \mathbf{a}_0) + \dots$$

- ▶ a minimumhelyen az első derivált definíció szerint 0
- ▶ a második derivált pozitív definit, az *irányonkénti* nagysága jellemzi, hogy „mennyire stabil” a minimum
- ▶ bízunk benne, hogy a magasabb rendű tagok kicsik

M változó esetén parciális második deriváltakat kell nézni:

- ▶ Hesse-mátrix

Pozitív definit kvadratikus kifejezés



A Hesse-mátrix inverze

Egy többváltozós függvény „görbületét” jellemzi. Írjuk fel a χ^2 -re:

$$2 \cdot \alpha_{kl} = \frac{\partial^2 \chi^2}{\partial a_k \partial a_l}$$

Állítás:

- ▶ az α_{kl} mátrix *inverze* jellemzi az illesztett paraméter standard hibáját
- ▶ az átlós elemekben σ_k^2 jelenik meg
- ▶ a nem diagonális elemekben a k . és l . paraméterek kovarianciája

Normál eloszlású mérési hibák és lineáris illesztés esetén ez egzaktul belátható, nem lineáris függvényillesztés esetén csak (jó) közelítés.

A paraméterek hibájának becslése más módon

A Hesse-mátrix csak analitikus modell esetében használható. Más modellek esetében próbálkozhatunk numerikus deriválással.

Egy jellegében más módszer: nézzük az illesztett paraméterek stabilitását úgy, hogy variáljuk a pontokat, amikre illesztünk

- ▶ erre a nagy ágyú módszer a Monte Carlo, de az bonyolult

Két egyszerűbb módszer:

- ▶ Jackknife módszer
- ▶ Bootstrapping

Jackknife² módszer

Tekintsük a mérési pontokat, de minden lépésben hagyjunk ki egyet az illesztésből

- ▶ hagyjuk ki az i . pontot
- ▶ illesszük a modellt $N - 1$ pontra
- ▶ legyen az illesztett paraméterek vektora θ_i

Minden egyes mérési pontra megismételve összesen N különböző paramétervektort kapunk

- ▶ ezek átlaga lesz a becsült paramétervektor

$$\theta_{\text{jack}} = \frac{1}{N} \sum_i \theta_i$$

- ▶ ezek szórása az illesztett paraméterek standard hibája

$$\sigma_{\text{jack}}^2 = \frac{N-1}{N} \sum_i (\theta_i - \theta_{\text{jack}})^2$$

²jackknife = bicska

Bootstrapping

Most válasszunk ki véletlenszerűen valamennyit az eredeti mérési pontokból, és illesszünk csak azokra


- ▶ ez elvileg $\binom{n}{k}$ módon megtehető, de nem kell ennyit végignézni

Az eljárás ugyanaz, mint az előző

- ▶ meghatározzuk a θ_i paramétervektorokat
- ▶ kiszámítjuk az átlagot és a szórást minden paraméterre

Mindkét módszer esetében számolhatjuk a paraméterek kovarianciáját is.

Konfidenciatartományok



Kilógó pontok

Egy mérés során becsúszhatnak rossz mérések


- ▶ ezeken nem jellemzi a mérési hiba
- ▶ valami miatt nem a mérési előírás szerint mérünk
- ▶ valamilyen ritka, nem várt esemény hatására

A modellillesztés során a kilógó pontoktól érdemes valamilyen módon megszabadulni.


Példa:

- ▶ egy távcső CCD detektorát a fotometriai mérés során egy nagy energiájú kozmikus részecske éri el, és nagy számú extra elektront gerjeszt

Kilógó pontok



Kilógó pontok



Kilógó pontok kezelése

Léteznek szofisztikált robusztus becslő módszerek, ezek bonyolultak.

- ▶ ezek a mérések hibáját nem normális eloszlásúnak, hanem hosszú farkúnak tételezik fel

Helyette nézzünk egy gyakori iteratív módszert

- ▶ illesszük a modellt a mérési pontokra
- ▶ számoljuk ki a mérési pontoktól vett eltérések szórását
- ▶ dobjuk ki azokat a pontokat, amik 3σ -n kívül esnek
- ▶ ismételjük meg az illesztést

A módszer kevés kilógó ponttal elbánik

- ▶ arra számítunk, hogy egy idő után nem lesz 3σ -n kívüli pont

Egyenes illesztése

Ismert:

- ▶ x_1, x_2, \dots, x_i mérési pontok, ezeknek nincs hibájuk
- ▶ y_1, y_2, \dots, y_i mért értékek
- ▶ $\sigma_1, \sigma_2, \dots, \sigma_i$ becsült hibák

Feladat: illesszünk a pontokra egyenest χ^2 módszerrel.

- ▶ modell: $y(x) = y(x|a, b) = a + bx$

Az optimalizálandó költségfüggvény:

$$\chi^2 = \sum_i \left(\frac{y_i - y(x_i|a, b)}{\sigma_i} \right)^2 = \sum_i \left(\frac{y_i - a - bx_i}{\sigma_i} \right)^2$$

Milyen a és b mellett lesz χ^2 minimális?

A minimum megkeresése

A költségfüggvény:

$$\chi^2(a, b) = \sum_i \left(\frac{y_i - a - bx_i}{\sigma_i} \right)^2$$

A minimumhelyen a parciális deriváltak eltűnnek:

$$\begin{aligned} 0 &= \frac{\partial \chi^2}{\partial a} = -2 \sum_i \frac{y_i - a - bx_i}{\sigma_i^2} \\ 0 &= \frac{\partial \chi^2}{\partial b} = -2 \sum_i \frac{x_i(y_i - a - bx_i)}{\sigma_i^2} \end{aligned}$$

Tudnivalók:

- ▶ Ez egy lineáris egyenletrendszer a -ra és b -re, csak ki kell bogarásznai az együtthatókat.
- ▶ Biztos, hogy minimumhelyet találunk, mert χ^2 kifejezése pozitív kvadratikus.

Új jelölések

Jelölések:

$$S = \sum_i \frac{1}{\sigma_i^2} \quad S_x = \sum_i \frac{x_i}{\sigma_i^2} \quad S_y = \sum_i \frac{y_i}{\sigma_i^2}$$

$$S_{xx} = \sum_i \frac{x_i^2}{\sigma_i^2} \quad S_{xy} = \sum_i \frac{x_i y_i}{\sigma_i^2}$$

Lineáris egyenletrendszer a -ra és b -re

Az új jelölésekkel az egyenletrendszer a -ra és b -re:

$$\begin{aligned}S_a + S_x b &= S_y \\S_x a + S_{xx} b &= S_{xy}\end{aligned}$$

Az egyenletrendszer determinánsa:

$$\Delta = S \cdot S_{xx} - S_x^2$$

Az egyenletrendszer megoldása:

$$a = \frac{S_{xx} \cdot S_y - S_x \cdot S_{xy}}{\Delta}$$

$$b = \frac{S \cdot S_{xy} - S_x \cdot S_y}{\Delta}$$

A megoldás hibájának meghatározása

Itt most azt nézzük, hogy az y_i mért értékek hibája mennyire befolyásolja a kapott a és b paraméterek bizonytalanságát.

A hibaterjedés törvénye szerint egy függvény értékének hibája:

$$\sigma_f^2 = \sum_i \sigma_i^2 \left(\frac{\partial f}{\partial y_i} \right)^2$$

Nekünk most az a és b paraméterek hibáját kell tekintenünk az y_i mért értékek függvényében, tehát:

$$\frac{\partial a}{\partial y_i} = \frac{S_{xx} - S_x x_i}{\sigma_i^2 \Delta} \qquad \frac{\partial b}{\partial y_i} = \frac{S x_i - S_x}{\sigma_i^2 \Delta}$$

Behelyettesítve:

$$\sigma_a^2 = \frac{S_{xx}}{\Delta} \qquad \sigma_b^2 = \frac{S}{\Delta}$$

Kiszámolható a kovariancia is: $\text{cov}_{ab} = -S_x/\Delta$

A Hesse-mátrix inverzével

A χ^2 parciális deriváltjait a és b szerint már kiszámoltuk a minimum keresésekor:

$$\frac{\partial \chi^2}{\partial a} = -2 \sum_i \frac{y_i - a - bx_i}{\sigma_i^2} \qquad \frac{\partial \chi^2}{\partial b} = -2 \sum_i \frac{x_i(y_i - a - bx_i)}{\sigma_i^2}$$

A második parciális deriváltakból alkotott Hesse-mátrix a korábbi jelölésekkel:

$$2 \cdot \alpha = \begin{pmatrix} \frac{\partial^2 \chi^2}{\partial a^2} & \frac{\partial^2 \chi^2}{\partial a \partial b} \\ \frac{\partial^2 \chi^2}{\partial b \partial a} & \frac{\partial^2 \chi^2}{\partial b^2} \end{pmatrix} = 2 \cdot \begin{pmatrix} S & S_x \\ S_x & S_{xx} \end{pmatrix}$$

Az α mátrixot invertálva kapjuk a hibákat és a kovarianciákat:

$$\alpha^{-1} = \begin{pmatrix} \sigma_a^2 & \text{cov}_{ab} \\ \text{cov}_{ab} & \sigma_b^2 \end{pmatrix} = \frac{1}{\Delta} \begin{pmatrix} S_{xx} & -S_x \\ -S_x & S \end{pmatrix}$$

Általános lineáris függvényillesztés

Nem csak az egyenesillesztés lineáris probléma. Keressük a modellt az általános $f(x|a_j)$ alakban.

- ▶ x lehet vektor is, de most nem írunk neki indexet
- ▶ ha x indexet kap, az a mérési pontokra vonatkozik majd
- ▶ a az M darab illesztendő paraméter
- ▶ ekkor $\chi^2 = \chi^2(a)$ is függeni fog a paraméterektől
- ▶ és persze y_i -ktől és σ_i -ktől is

Tekintsük a χ^2 parciális deriváltjaira a minimumban teljesülő feltételeket.

$$\frac{\partial \chi^2}{\partial a_j} = 0$$

Elvégezve a parciális deriválást

χ^2 korábbi definíciója alapján a deriváltakra adódó feltétel:

$$\frac{\partial \chi^2}{\partial a_j} = 2 \cdot \sum_{i=1}^N \left[\frac{f(x_i|a) - y_i}{\sigma_i^2} \cdot \frac{\partial f(x|a)}{\partial a_j} \Bigg|_{x=x_i} \right] = 0$$

Eddig a pontig nem tettünk fel semmit $f(x|a)$ konkrét alakjáról

- ▶ nem is tudunk egyszerű megoldást adni
- ▶ a $\frac{\partial f(x|a)}{\partial a_j}$ derivált lehet nagyon bonyolult

Ötlet: korlátozzuk a problémát olyan esetekre, amikor a parciális derivált nem függ az a_j paraméterektől.

A lineáris probléma

Keressük $f(x|a)$ -t a következő alakban:

$$f(x|a) = \sum_{j=1}^M a_j f_j(x),$$

ahol $f_j(x)$ tetszőleges ún. **bázisfüggvény**, ami már nem függ az a_j -ktől.

- ▶ A probléma lineáris, mert a teljes $f(x|a)$ a különböző $f_j(x)$ -ek lineárkombinációja.
- ▶ Az $f_j(x)$ -ek konkrét alakja tetszőleges.

Így már el tudjuk végezni a parciális deriválást:

$$\frac{\partial f(x|a)}{\partial a_k} = f_k(x),$$

hiszen

$$\frac{\partial (a_j f_j(x))}{\partial a_k} = \delta_{jk} f_j(x)$$

A megoldandó lineáris egyenletrendszer

Behelyettesítve az f tetszőleges függvények lineárkombinációjából álló alakját a következő adódik:

$$\frac{\partial \chi^2(a_j)}{\partial a_j} = 2 \cdot \sum_{i=1}^N \left[\frac{1}{\sigma_i^2} \cdot \left(\sum_{k=1}^M a_k f_k(x_i) - y_i \right) \cdot f_j(x_i) \right] = 0$$

A szögletes zárójelen belüli szorzat harmadik tagjában azért nincsen már \sum , mert a Kronecker- δ elvitte a többi tagot.

Vegyük észre, hogy ez már lineáris egyenletrendszer az a_k együtthatókra.

A tervmátrix³

A probléma innentől már csak egy lineáris egyenletrendszer megoldása. Az átláthatóság kedvéért vezessük be a következőket:

$$X_{ij} = \frac{f_j(x_i)}{\sigma_i} \qquad b_i = \frac{y_i}{\sigma_i}$$

X_{ij} az úgynevezett *tervmátrix*:

- ▶ az M oszlopa a bázisfüggvényeknek felel meg
- ▶ az N sora a mérési pontoknak
- ▶ a mátrixelemek a j . bázisfüggvény x_i helyeken vett értékei

³design matrix

A tervmátrix és a b_i vektor felépítése

$$X_{ij} = \begin{pmatrix} \frac{f_1(x_1)}{\sigma_1} & \frac{f_2(x_1)}{\sigma_1} & \dots & \frac{f_M(x_1)}{\sigma_1} \\ \frac{f_1(x_2)}{\sigma_2} & \frac{f_2(x_2)}{\sigma_2} & \dots & \frac{f_M(x_2)}{\sigma_2} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ \frac{f_1(x_N)}{\sigma_N} & \frac{f_2(x_N)}{\sigma_N} & \dots & \frac{f_M(x_N)}{\sigma_N} \end{pmatrix} \quad b_i = \begin{pmatrix} \frac{y_1}{\sigma_1} \\ \frac{y_2}{\sigma_2} \\ \vdots \\ \vdots \\ \frac{y_N}{\sigma_N} \end{pmatrix}$$

A lineáris illesztés normálegyenletei

A parciális deriváltakra felírt egyenletek ezzel:

$$\sum_{i=1}^N \left[\left(\sum_{k=1}^M a_k X_{ik} - b_i \right) \cdot X_{ij} \right] = 0,$$

ami indexes írásmóddal:

$$X_{ik} a_k X_{ij} = X_{ij} b_i$$

Kibogozva az indexet a következő mátrixegyenletet kapjuk:

$$\mathbf{X}^T \mathbf{X} \mathbf{a} = \mathbf{X}^T \mathbf{b},$$

ahol \mathbf{X} egy $N \times M$ -es mátrix, tehát végső soron M darab M ismeretlenes egyenletet kell megoldani, például Gauss-eliminációval.

Az Hesse-mátrix

$$(\mathbf{X}\mathbf{a} - \mathbf{y})_i = \sum_j x_i^{(j-1)} a_j - y_i$$

$$\chi^2 = \sum_i \left[\sum_j \left(x_i^{(j-1)} a_j \right) - y_i \right]^2$$

$$\frac{\partial \chi^2}{\partial a_k} = 2 \cdot \sum_i \left[\sum_j x_i^{(k-1)} x_i^{(j-1)} a_j - x_i^{(k-1)} y_i \right]$$

$$\frac{\partial^2 \chi^2}{\partial a_k \partial a_l} = 2 \cdot \sum_i \left[x_i^{(k-1)} x_i^{(l-1)} \right]$$

Az illesztett paraméterek hibája

A második parciális deriváltakból álló Hesse-mátrix valójában egyszerűen

$$\alpha = \mathbf{X}^T \mathbf{X}$$

Ennek az inverze adja a kovarianciamátrixot:

$$\mathbf{C} = \alpha^{-1}$$

- ▶ az átlós elemek a varianciákat tartalmazzák: $\sigma_k^2 = C_{kk}$
- ▶ a többi a kovarianciákat: $\text{cov}_{kl} = C_{kl}$

Az illesztés aszimptotikus hibájának általában a redukált χ^2 -tel szorzott varianciát vesszük.

Többváltozós polinomillesztés

Ha az x_i mérési pontok maguk is $x_i^{(k)}$ K -dimenziós vektorok, akkor a többdimenziós polinomillesztés modellje a következő:

$$f_j^{(k)}(x) = \sum_{p=1}^{M \cdot K} a_p x^{j-1},$$

- ▶ a probléma immár összesen $M \cdot K$ ismeretlent fog tartalmazni
- ▶ de ebben még nincsenek vegyes tagok
- ▶ a p index a j és k indexekből képzett rendezett párok halmazán (Descartes-szorzat) fut
- ▶ a probléma ugyanúgy oldható meg, mint az előző
- ▶ a végén $M \cdot K \times M \cdot K$ méretű mátrixot kell invertálni

Példa: parabola illesztése 5 pontra

Mivel öt megadott pont esetében a parabolaillesztés túlhatározott, a legkisebb négyzetek módszerét használjuk. Legyenek a mérési adatok a következők (valójában oszlopvektorok):

$$\mathbf{x} = \{ -2, -1, 0, 1, 2 \}$$
$$\mathbf{y} = \{ 5.1, 1.9, 1.1, 2.1, 4.9 \}$$

A modell három ismeretlenes: $f(x) = a_0 + a_1x + a_2x^2$, azaz $f_1(x) = 1$, $f_2(x) = x$ és $f_3(x) = x^2$. Ezzel:

$$\mathbf{X} = \begin{bmatrix} 1 & -2 & 4 \\ 1 & -1 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{bmatrix} \quad \mathbf{X}^T \mathbf{X} = \begin{bmatrix} 5 & 0 & 10 \\ 0 & 10 & 0 \\ 10 & 0 & 34 \end{bmatrix} \quad \mathbf{X}^T \mathbf{y} = \begin{bmatrix} 15.1 \\ -0.2 \\ 44.0 \end{bmatrix}$$

A függvényillesztés eredménye


Az $\mathbf{X}^T \mathbf{X} \mathbf{a} = \mathbf{X}^T \mathbf{y}$ egyenletet \mathbf{a} -ra megoldva:

$$\mathbf{a} = \begin{bmatrix} 1.049 \\ -0.020 \\ 0.986 \end{bmatrix}$$

Az illesztés jósága:

$$\begin{aligned} \chi^2 &= (\mathbf{X} \mathbf{a} - \mathbf{y})^2 \\ &= 0.0411 \end{aligned}$$

$$\frac{\chi^2}{\text{NDF}} = \frac{0.0411}{5 - 3} = 0.0206$$



A konkrét példában

Az illesztett modell:

$$\hat{f}(x) = 1.049 - 0.020x + 0.986x^2$$

A kovarianciamátrix:

$$(\mathbf{X}^T \mathbf{X})^{-1} = \begin{bmatrix} 5 & 0 & 10 \\ 0 & 10 & 0 \\ 10 & 0 & 34 \end{bmatrix}^{-1} = \begin{bmatrix} 0.49 & 0 & -0.14 \\ 0 & 0.10 & 0 \\ -0.14 & 0 & 0.07 \end{bmatrix}$$

Vagyis az egyes paraméterek szórása és kovarianciája:

$$\begin{aligned}\sigma_0 &= 0.70 \\ \sigma_1 &= 0.32 \\ \sigma_2 &= 0.27 \\ \text{cov}_{02} &= -0.14\end{aligned}$$

χ^2/NDF -fel szorozva az aszimptotikus hibák:

$$\begin{aligned}\tilde{\sigma}_0 &= 0.1000 \\ \tilde{\sigma}_1 &= 0.0454 \\ \tilde{\sigma}_2 &= 0.0384\end{aligned}$$